



# Clusterização

Alunos: Anderson Santos, Izaquiel Queiroz

Professor: Paulo Neto

Disciplina: Reconhecimento de Padrões e Aprendizado de Máquina

---

# Aprendizado não supervisionado



# Aprendizado não supervisionado

A set of statistical tools intended for the setting in which we have only a set of features  $X_1, X_2, \dots, X_p$  measured on  $n$  observations. The goal is to discover interesting things about the measurements on  $X_1, X_2, \dots, X_p$ .

Is there an informative way to visualize the data? Can we discover subgroups among the variables or among the observations?

(James, Gareth, et al., 2013)

—

# Clusterização



# Clusterização

Clustering refers to a very broad set of techniques for finding subgroups, or clustering clusters, in a data set. (James, Gareth, et al., 2013)

Essa divisão é feita de modo que os grupos sejam diferentes uns dos outros, mas os elementos pertencentes ao mesmo grupo sejam parecidos entre si. (Izbicki, Rafael, and Tiago Mendonça dos Santos, 2020)

---

# Medidas de (dis)similaridade



# Medidas

Distância Euclidiana

Distância Manhattan

Distância de Mahalanobis

Distância Cosseno

Distância de Jaccard



# Medidas

→ Distância Euclidiana

Distância Manhattan

Distância de Mahalanobis

Distância Cosseno

Distância de Jaccard

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^d (x_{i,k} - x_{j,k})^2;$$





# Medidas

Distância Euclidiana

→ Distância Manhattan

Distância de Mahalanobis

Distância Cosseno

Distância de Jaccard

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$



# Medidas

Distância Euclidiana

Distância Manhattan

→ Distância de Mahalanobis

Distância Cosseno

Distância de Jaccard

$$d(x^T, y^T) = \sqrt{(x - y)S^{-1}(x - y)^T}$$

$$S = \text{matriz}(s_{kj}) = \frac{1}{n} \sum_{i=1}^n (x_{ik} - \bar{x}_k)(x_{ij} - \bar{x}_j)$$



# Medidas

Distância Euclidiana

Distância Manhattan

Distância de Mahalanobis

→ Distância Cosseno

Distância de Jaccard

$$d(\mathbf{x}_i, \mathbf{x}_j) = 1 - \frac{\mathbf{x}_i \cdot \mathbf{x}_j}{\|\mathbf{x}_i\| \|\mathbf{x}_j\|};$$



# Medidas

Distância Euclidiana

Distância Manhattan

Distância de Mahalanobis

Distância cosseno

→ Distância de Jaccard

$$d(\mathbf{x}_i, \mathbf{x}_j) = 1 - \frac{\sum_{k=1}^d x_{i,k} x_{j,k}}{\sum_{k=1}^d x_{i,k} + \sum_{k=1}^d x_{j,k} - \sum_{k=1}^d x_{i,k} x_{j,k}}$$

—

# Algoritmos

# K-Means

---



# K-Means

K-means clustering is a simple and elegant approach for partitioning a data set into  $K$  distinct, non-overlapping clusters. We seek to partition the observations into a pre-specified number of clusters. (James, Gareth, et al., 2013)

The goal is to partition the data set into some number  $K$  of clusters, where we shall suppose for the moment that the value of  $K$  is given. A cluster as comprising a group of data points whose inter-point distances are small compared with the distances to points outside of the cluster. (Bishop, Christopher M., 2006)



# Pseudocódigo

---

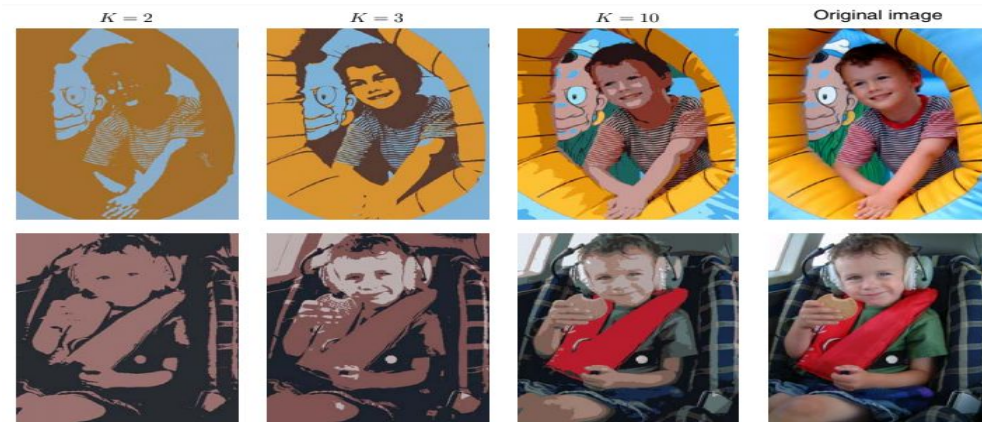
## Algorithm 10.1 *K-Means Clustering*

---

1. Randomly assign a number, from 1 to  $K$ , to each of the observations. These serve as initial cluster assignments for the observations.
  2. Iterate until the cluster assignments stop changing:
    - (a) For each of the  $K$  clusters, compute the cluster *centroid*. The  $k$ th cluster centroid is the vector of the  $p$  feature means for the observations in the  $k$ th cluster.
    - (b) Assign each observation to the cluster whose centroid is closest (where *closest* is defined using Euclidean distance).
-



# Aplicações



**Figure 9.3** Two examples of the application of the  $K$ -means clustering algorithm to image segmentation showing the initial images together with their  $K$ -means segmentations obtained using various values of  $K$ . This also illustrates the use of vector quantization for data compression, in which smaller values of  $K$  give higher compression at the expense of poorer image quality.



## Exemplo



# Self-Organizing Map (SOM)

---



# Introdução


Foi desenvolvida por Kohonen na década de 80

São baseadas no mapa topológico presente no córtex cerebral. Neurônios topologicamente próximos tendem a responder a padrões ou estímulos semelhantes

A cada iteração, os neurônios se especializam em agrupamentos de padrões similares

Utiliza o paradigma da aprendizagem competitiva

# Arquitetura





# Algoritmo

1. Inicialização: geralmente aleatória
2. Competição: para cada padrão de entrada, calcula-se a resposta dos neurônios de saída. O neurônio com a maior resposta é o vencedor da competição. Denomina-se tal neurônio como BMU (Best Matching Unit)
3. Cooperação: o neurônio vencedor define uma vizinhança topológica (em função da grade) de neurônios excitados
4. Adaptação Sináptica: aprendizado em relação ao padrão de entrada. Os pesos do neurônio vencedor, e de sua vizinhança, ficam mais próximos do padrão de entrada



# Competição

Obtenção do BMU por:

$$v = \arg \min_j \|\mathbf{x} - \mathbf{w}_j\|, \quad j = 1, 2, \dots, N$$


É baseado na maximização do produto interno. Matematicamente equivalente a minimizar a distância euclidiana entre  $\mathbf{x}$  e  $\mathbf{w}$

# Processo Cooperativo

Compreende a definição de uma função de vizinhança centrada no neurônio vencedor

Define uma região de neurônios cooperativos, que terão seus pesos ajustados juntamente com o neurônio vencedor

Há diversas formas de implementar a função de vizinhança. A função mais utilizada como função de vizinhança é a Gaussiana.





# Adaptação Sináptica

Modificação dos pesos em relação à entrada, de forma iterativa

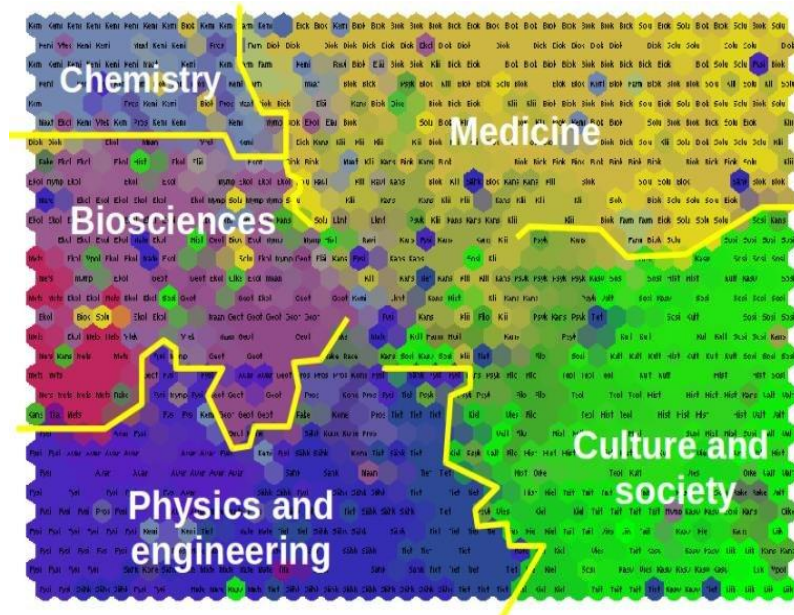
A equação abaixo é aplicada a todos os neurônios da grade dentro da região de vizinhança

$$\mathbf{w}_j(t + 1) = \mathbf{w}_j(t) + \eta(t)h_{vj}(t)[\mathbf{x} - \mathbf{w}_j(t)]$$

The diagram illustrates the synaptic adaptation equation. A rectangular box contains the equation  $\mathbf{w}_j(t + 1) = \mathbf{w}_j(t) + \eta(t)h_{vj}(t)[\mathbf{x} - \mathbf{w}_j(t)]$ . Below the box, five labels are positioned with arrows pointing to specific terms in the equation: 'Vetor peso atualizado' points to  $\mathbf{w}_j(t + 1)$ , 'Vetor peso anterior' points to  $\mathbf{w}_j(t)$ , 'Taxa de aprendizagem' points to  $\eta(t)$ , 'Vizinhança' points to  $h_{vj}(t)$ , and 'Adaptação' points to the entire right-hand side of the equation.


Vetor peso atualizado      Vetor peso anterior      Taxa de aprendizagem      Vizinhança      Adaptação

# Aplicações





# Aplicações





## Exemplo



---

# Outras abordagens



# Abordagem hierárquica

Métodos hierárquicos são uma alternativa que evitam o problema de especificar de antemão o valor do K

São representados visualmente por meio de dendrogramas

Pseudocódigo base:

1. Atribua cada observação a um cluster diferente. Calcule cada uma das  $\binom{n}{2}$  distâncias entre esses clusters
2. Para  $i=n, n-1, \dots, 2$ :
  - a. Procure entre todos os pares formados por dois dos  $i$  clusters aqueles mais parecidos. Junte esses dois clusters em um só. A dissimilaridade entre esses dois clusters indica a altura do dendrograma em que a junção será feita
  - b. Calcule cada uma das distâncias entre os novos  $i-1$  clusters



# Linkage

Para fazer o agrupamento é necessário definir a distância entre dois clusters. Há várias formas de se definir essas distâncias chamadas de linkage

**Complete:** a maior das distâncias entre todos os pares de observações pertencentes aos dois clusters.

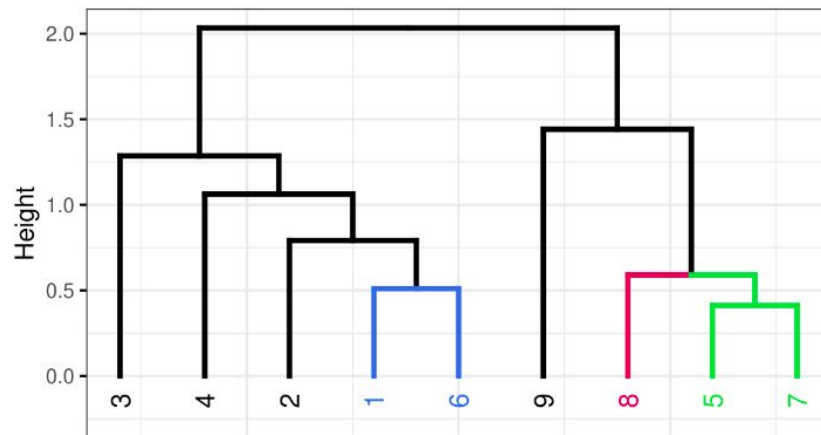
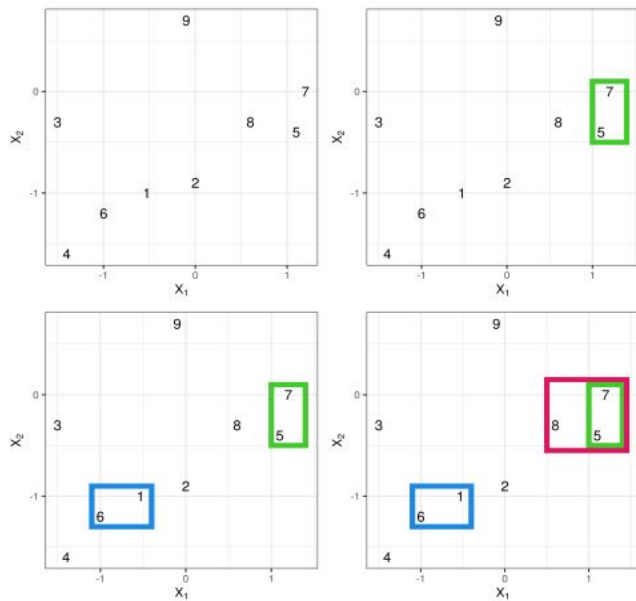
**Single:** a menor das distâncias entre todos os pares de observações pertencentes aos dois clusters.

**Average:** a média das distâncias entre todos os pares de observações pertencentes aos dois clusters.

**Centroid:** a distância entre os centróides dos dois clusters



# Exemplo



---

# Referências



## Referências

1. Bishop, Christopher M. Pattern recognition and machine learning. springer, 2006.
2. Izbicki, Rafael, and Tiago Mendonça dos Santos. Aprendizado de máquina: uma abordagem estatística. Rafael Izbicki, 2020.
3. James, Gareth, et al. An introduction to statistical learning. Vol. 112. New York: Springer, 2013.

### **Complementar:**

4. Stork, D. G., Duda, R. O., Hart, P. E., & Stork, D. (2001). Pattern classification. A Wiley-Interscience Publication.
5. De Sa, JP Marques. Pattern recognition: concepts, methods and applications. Springer Science & Business Media, 2012.
6. Murty, M. Narasimha, and V. Susheela Devi. Introduction to pattern recognition and machine learning. Vol. 5. World Scientific, 2015.